

TRABAJO FINAL



**PRESENTADO POR:
DAVID SANTIAGO AGUIRRE POLANCO
MARÍA JUANITA ROJAS CHACÓN**

**PRESENTADO A:
PROFESOR JUAN NICOLÁS VELÁSQUEZ REY**

**ANALÍTICA DE LOS NEGOCIOS
TRABAJO FINAL**

**PONTIFICIA UNIVERSIDAD JAVERIANA
BOGOTÁ, D.C.
MAYO
2026**

Contenido

1. Introducción	4
1.1 Contexto del problema	4
1.2 Justificación del estudio	4
1.3 Pregunta problema.....	4
1.4 Objetivo principal.....	4
1.5 Objetivos específicos.....	5
2. Descripción de la base de datos	6
2.1 Fuente de los datos (TLC y NOAA)	6
2.2 Proceso de construcción y limpieza	6
2.3 Descripción de variables	7
2.4 Alcance y limitaciones de la base	9
3. Análisis exploratorio de datos.....	9
3.1 Estadísticos descriptivos	9
3.2 Justificación de la transformación logarítmica.....	10
3.3 Comportamiento de la demanda por variable	13
3.4 Resumen por barrio de origen	17
4. Diferencias en la demanda de viajes	17
4.1 Metodología (pruebas t y ANOVA).....	17
4.2 Festivos vs. días ordinarios	18
4.3 Horas pico vs. horas valle	19
4.4 Comparación entre barrios	21
5. Modelo econométrico de la demanda	22
5.1 Especificación del modelo	22
5.2 Construcción progresiva del modelo.....	23
5.2.1 Modelo 1: Variables temporales.....	24
5.2.2 Modelo 2: + Variables geográficas.....	25
5.2.3 Modelo 3: + Variables operativas.....	25
5.2.4 Modelo 4: + Variables climáticas.....	25
5.3 Selección del modelo final	26
6. Evaluación y validación del modelo	28
6.1 Bondad de ajuste (R^2 y R^2 ajustado).....	28
6.2 Análisis de residuos.....	28

6.3 Verificación de supuestos.....	29
6.3.1 Normalidad	29
6.3.2 Homocedasticidad	30
6.3.3 Linealidad	31
6.4 Heterogeneidad por barrio.....	31
7. Dashboard interactivo	32
7.1 Descripción general del dashboard	32
7.2 Módulo predictor de viajes.....	33
7.3 Módulo estimador de tarifa	34
7.4 Módulo comparador de barrios	34
7.5 Módulo análisis por hora.....	35
7.6 Implementación en Shiny.....	36
8. Discusión de resultados.....	36
8.1 Principales hallazgos	36
8.2 Implicaciones económicas.....	37
8.3 Limitaciones del estudio.....	37
9. Conclusiones y Recomendaciones.....	38

1. Introducción

1.1 Contexto del problema

El transporte urbano constituye un componente fundamental en el funcionamiento de las grandes ciudades, especialmente en contextos altamente dinámicos como Nueva York. En este entorno, los taxis amarillos representan uno de los principales medios de movilidad, ya que conectan múltiples zonas de la ciudad y responden de manera flexible a las variaciones en la demanda de los usuarios. Sin embargo, dicha demanda no es constante, sino que fluctúa significativamente a lo largo del tiempo en función de factores como la hora del día, la ubicación geográfica y las condiciones climáticas. Comprender estos patrones resulta clave para optimizar la asignación de recursos, mejorar la eficiencia del servicio y facilitar la toma de decisiones tanto para empresas del sector como para autoridades regulatorias.

1.2 Justificación del estudio

El análisis de la demanda de servicios de transporte, particularmente en sistemas como el de taxis, tiene implicaciones directas sobre la eficiencia operativa y la planificación estratégica. Identificar los determinantes que explican el número de viajes permite anticipar comportamientos de los usuarios y ajustar la oferta de manera más precisa. Además, la incorporación de variables climáticas y temporales aporta un enfoque más integral, ya que estos factores suelen influir de manera significativa en las decisiones de movilidad. Este estudio se justifica en la necesidad de generar evidencia empírica que permita entender cómo interactúan estos elementos y cómo varían entre diferentes zonas de la ciudad, contribuyendo así a mejorar la gestión del transporte urbano.

1.3 Pregunta problema

En este contexto, surge la siguiente pregunta de investigación: ¿Qué factores temporales, geográficos y climáticos determinan el número de viajes diarios de taxis amarillos en Nueva York durante 2024, y en qué medida varía este comportamiento según el barrio de origen y la hora del día?

1.4 Objetivo principal

El objetivo principal de este estudio es evaluar los determinantes de la demanda de viajes de taxi amarillo en Nueva York durante el año 2024, utilizando registros oficiales del Taxi & Limousine Commission (TLC), complementados con información climática proveniente de la estación Central Park de la National Oceanic and Atmospheric Administration (NOAA).

1.5 Objetivos específicos

En primer lugar, se busca analizar si existen diferencias estadísticamente significativas en el número promedio de viajes (`trip_count`) entre distintos contextos relevantes de la demanda. Específicamente, se compararán los días festivos frente a los días ordinarios, las horas pico (7:00–9:00 y 17:00–19:00) frente a las horas valle, y los distintos barrios de origen de la ciudad de Nueva York (Manhattan, Brooklyn, Bronx, Queens, Staten Island y EWR). Este análisis se llevará a cabo mediante pruebas de diferencias de medias, utilizando intervalos de confianza al 95%, y estará acompañado de visualizaciones descriptivas que permitan respaldar e interpretar los resultados obtenidos.

En segundo lugar, se propone estimar un modelo econométrico de regresión que permita explicar el comportamiento de la demanda de viajes, tomando como variable dependiente la transformación logarítmica de `trip_count`. El modelo será construido de manera progresiva, incorporando variables en distintas etapas, comenzando por factores temporales y geográficos, y posteriormente integrando variables operativas y climáticas, como el tipo de pago, la temperatura máxima y la presencia de lluvia. En cada etapa se evaluará el desempeño del modelo mediante la estimación de coeficientes, sus respectivos intervalos de confianza y medidas de ajuste como el R^2 y el R^2 ajustado. Asimismo, se seleccionará un modelo final que cumpla con los supuestos clásicos de la regresión lineal, particularmente la normalidad de los residuos y la homocedasticidad, los cuales serán verificados a través de herramientas gráficas. Adicionalmente, se analizará la posible heterogeneidad en la demanda mediante la comparación de coeficientes entre distintos barrios de origen.

Finalmente, se desarrollará un dashboard interactivo utilizando la librería Shiny en R, orientado a facilitar la interpretación y aplicación práctica de los resultados por parte de usuarios del sector transporte. El dashboard estará estructurado en cuatro módulos principales. El primero corresponderá a un predictor de viajes, que permitirá estimar en tiempo real el número esperado de viajes a partir de variables seleccionadas por el usuario, como barrio de origen, hora del día, tipo de pago, temperatura y lluvia. El segundo módulo consistirá en un estimador de tarifa, donde el usuario podrá visualizar el valor promedio estimado por viaje, calculado a partir de la relación entre la tarifa total y el número de viajes del grupo correspondiente. El tercer módulo será un comparador de barrios que permita evidenciar diferencias en la demanda entre distintos orígenes y destinos dentro de la ciudad. Finalmente, el cuarto módulo presentará un análisis horario de la demanda, mostrando la evolución del número de viajes a lo largo del día y diferenciando entre horas pico y horas valle. La aplicación fue desarrollada en la librería Shiny de R y puede ejecutarse localmente desde RStudio como herramienta de apoyo para la toma de decisiones.

2. Descripción de la base de datos

2.1 Fuente de los datos (TLC y NOAA)

La base de datos utilizada en este estudio proviene de la integración de dos fuentes oficiales. En primer lugar, se emplean los registros administrativos del Taxi & Limousine Commission (TLC) de la ciudad de Nueva York, los cuales contienen información detallada sobre los viajes realizados por taxis amarillos durante el año 2024. Esta fuente incluye variables relacionadas con la operación del servicio, tales como número de viajes, ubicación de origen y destino, tipo de pago, número de pasajeros, distancia recorrida y montos asociados a las tarifas.

En segundo lugar, se incorporan datos climáticos provenientes de la estación meteorológica de Central Park, administrada por la National Oceanic and Atmospheric Administration (NOAA). Esta información permite complementar la base principal con variables relevantes como la temperatura máxima diaria y el nivel de precipitación, las cuales son potencialmente determinantes en el comportamiento de la demanda de transporte. La combinación de ambas fuentes permite construir una base de datos más robusta, integrando factores operativos, geográficos y climáticos.

2.2 Proceso de construcción y limpieza

El proceso de construcción de la base de datos incluyó etapas de depuración, transformación e integración de información proveniente de distintas fuentes. Inicialmente, la base original del NYC Taxi & Limousine Commission (TLC) contaba con 921,373 registros correspondientes a viajes de taxis amarillos en Nueva York durante 2024. Posteriormente, se identificaron observaciones con valores desconocidos en las variables de barrio de origen (PU_Borough) y barrio de destino (DO_Borough), así como registros inconsistentes asociados a información operativa incompleta. Dado que el objetivo principal del estudio se centra en el análisis geográfico y temporal de la demanda, estos registros fueron excluidos del análisis. Como resultado del proceso de depuración, la base final quedó conformada por 637,925 observaciones válidas.

Con el fin de garantizar que la eliminación de registros no alterara de manera sustancial la estructura de la muestra, se realizaron pruebas estadísticas comparando la distribución de la variable trip_count antes y después del filtro. Los resultados muestran que, aunque el promedio aumentó debido a la eliminación de observaciones de muy baja demanda, la mediana se mantuvo constante y la distribución general conservó un comportamiento similar. Asimismo, la composición porcentual de los barrios presentó variaciones mínimas, lo que indica que el proceso de limpieza no generó sesgos relevantes en la representación geográfica de los datos.

Momento	N	Media	Mediana	Asimetría
Antes del filtro	921,373	42.74	3	11.92
Después del filtro	637,925	54.68	3	10.28

Tabla 1. Impacto del filtro sobre los estadísticos de trip_count.

Barrio	% antes del filtro	% después del filtro	Diferencia
Manhattan	46.69%	46.54%	-0.15
Queens	38.00%	39.46%	1.46
Brooklyn	10.55%	10.00%	-0.55
Bronx	4.53%	3.82%	-0.71
EWR	0.11%	0.14%	0.03
Staten Island	0.11%	0.04%	-0.07

Tabla 2. Distribución porcentual por barrio antes y después del filtro.

Adicionalmente, se construyeron nuevas variables, entre ellas se encuentra holiday_usa, elaborada a partir del calendario de festivos federales de Estados Unidos, y fare_per_trip, calculada como el cociente entre fare_amount_sum y trip_count, utilizada posteriormente en el módulo de estimación de tarifas. Finalmente, se integraron los datos climáticos provenientes de la estación Central Park de NOAA mediante correspondencia temporal diaria, asegurando que cada observación incluyera la información meteorológica correspondiente a la fecha del viaje. Este proceso permitió consolidar una base de datos consistente, robusta y adecuada para el análisis estadístico y econométrico del estudio.

2.3 Descripción de variables

La base de datos final está compuesta por un total de 22 variables, de las cuales 18 provienen directamente de los registros del TLC y 4 fueron incorporadas o transformadas como parte del proceso de construcción.

Variable	Tipo	Descripción
date	Fecha	Fecha del registro, desde el 1 de enero hasta el 31 de diciembre de 2024.
hour	Numérica	Hora del día en formato de 24 horas (0 a 23).
passenger_count	Numérica	Promedio de pasajeros por viaje registrado en esa hora y zona.

PU_Borough	Categorica	Barrio de recogida del pasajero: Manhattan, Brooklyn, Bronx, Queens, Staten Island o EWR (Aeropuerto Internacional Newark).
DO_Borough	Categorica	Barrio de destino del viaje.
payment_type	Dummy	Método de pago: 1 = tarjeta de crédito, 2 = efectivo.
trip_count	Numérica	Número de viajes realizados en esa hora, barrio y tipo de pago.
trip_distance_sum	Numérica	Suma de las distancias recorridas en todos los viajes del grupo (millas).
duration_sum	Numérica	Suma de la duración total de los viajes del grupo (minutos).
fare_amount_sum	Numérica	Suma de las tarifas base cobradas en el grupo (USD).
extra_sum	Numérica	Suma de cargos adicionales, incluyendo recargo nocturno y hora pico (USD).
mta_tax_sum	Numérica	Suma del impuesto MTA obligatorio de \$0.50 por viaje (USD).
tip_amount_sum	Numérica	Suma de propinas recibidas. Solo aplica a pagos con tarjeta de crédito (USD).
tolls_amount_sum	Numérica	Suma de peajes pagados durante los viajes del grupo (USD).
improvement_surcharge_sum	Numérica	Suma del recargo de mejora vial de \$0.30 por viaje (USD).
congestion_surcharge_sum	Numérica	Suma del recargo por congestión vehicular aplicado en la zona sur de Manhattan (USD).
airport_fee_sum	Numérica	Suma de tarifas de aeropuerto. Solo aplica en viajes con origen o destino en JFK o LaGuardia (USD).
total_amount_sum	Numérica	Suma del monto total cobrado incluyendo tarifa, propinas y todos los cargos (USD).
holiday_usa	Dummy	Indica si el día es festivo federal en EE.UU.: 1 = sí es festivo, 0 = día ordinario.
tmax_f	Numérica	Temperatura máxima del día en grados Fahrenheit. Fuente: NOAA, estación Central Park NYC.
prcp_in	Numérica	Precipitación del día en pulgadas. 0.00 indica sin lluvia. Fuente: NOAA, estación Central Park NYC.
rain	Dummy	Indica si hubo lluvia ese día: 1 = llovió, 0 = no llovió.

Tabla 3. Descripción de variables utilizadas en el análisis.

2.4 Alcance y limitaciones de la base

La base de datos presenta un tamaño y nivel de detalle que permiten capturar patrones de comportamiento con un alto grado de precisión, al contar con cerca de 800 mil observaciones. En segundo lugar, la integración de variables de distinta naturaleza operativas, temporales, geográficas y climáticas, proporciona un enfoque integral para el estudio de la demanda de transporte.

No obstante, también existen algunas limitaciones que deben ser consideradas al interpretar los resultados. En particular, la información se restringe a los taxis amarillos, por lo que no incluye otros medios de transporte como plataformas digitales (por ejemplo, servicios de transporte por aplicación), lo cual podría afectar la representatividad de la demanda total. Asimismo, las variables climáticas se obtienen de una única estación meteorológica (Central Park), lo que puede no reflejar completamente las variaciones microclimáticas en toda la ciudad. Finalmente, aunque la base incluye múltiples variables explicativas, pueden existir factores no observados como eventos especiales o cambios en la movilidad urbana que no están capturados en los datos.

3. Análisis exploratorio de datos

3.1 Estadísticos descriptivos

Con el fin de caracterizar la distribución y comportamiento general de las variables incluidas en el análisis, se calcularon estadísticos descriptivos para las principales variables numéricas de la base de datos. Estos resultados permiten obtener una primera aproximación a la magnitud, dispersión y posibles patrones presentes en los datos, así como identificar la existencia de valores atípicos o distribuciones sesgadas que puedan influir en los análisis posteriores.

Variable	Mínimo	Promedio	Mediana	Desviación	Máximo
trip_count	1	54.68	3	319.4	7,242
log_trip_count	0.69	1.93	1.39	1.47	8.89
hour	0	12.66	13	6.68	23
passenger_count	1	2.18	2	1.29	5
tmax_f	21	65.5	68	17.07	95 °F
prcp_in	0	0.13	0	0.37	3.66
fare_amount_sum	3	1,047.79	119.75	4,616.63	105,949 USD
total_amount_sum	4	1,575.56	151.5	7,473.86	183,673 USD

Tabla 4. Estadísticos descriptivos de las variables numéricas.

Los resultados evidencian que la variable `trip_count` presenta una alta dispersión, con un promedio de 54.68 viajes y una desviación estándar de 319.40, considerablemente superior a la media. Asimismo, la diferencia entre la media y la mediana (3 viajes) refleja una distribución fuertemente asimétrica hacia la derecha, donde la mayoría de las observaciones se concentra en valores bajos, mientras que un grupo reducido alcanza niveles extremadamente altos de demanda, con máximos de hasta 7,242 viajes.

En cuanto a las variables temporales, la variable `hour` presenta una distribución relativamente equilibrada a lo largo del día, con un promedio cercano a las 12:00 horas, lo que indica una adecuada representación de todas las franjas horarias. Por otro lado, las variables climáticas muestran una temperatura máxima promedio de 65.50 °F y niveles bajos de precipitación, dado que la mediana de `prcp_in` es igual a cero, lo que sugiere que gran parte de los días analizados no registró lluvias significativas.

Finalmente, las variables relacionadas con la operación del servicio, como `fare_amount_sum` y `total_amount_sum`, también exhiben altos niveles de dispersión y valores máximos elevados, consistentes con la existencia de trayectos de gran magnitud y episodios de alta demanda, especialmente en zonas con mayor actividad económica y movilidad. En conjunto, estos resultados evidencian una importante heterogeneidad en los datos y anticipan la necesidad de aplicar transformaciones y herramientas econométricas robustas en las siguientes etapas del análisis.

3.2 Justificación de la transformación logarítmica

El análisis inicial de la variable dependiente `trip_count` evidencia una distribución altamente asimétrica hacia la derecha, caracterizada por una fuerte concentración de observaciones en valores bajos y la presencia de valores extremos considerablemente elevados. Aunque la mediana de la variable corresponde a únicamente 3 viajes, existen registros que alcanzan hasta 7,242 viajes, lo que genera una dispersión muy elevada y una distribución con cola larga. Esta situación se refleja en los indicadores estadísticos de forma, donde la asimetría alcanza un valor de 10.28 y la curtosis asciende a 121.58, evidenciando una desviación importante respecto a una distribución normal.

Estas características representan un problema para la estimación de modelos de regresión lineal, ya que la presencia de valores extremos y distribuciones altamente sesgadas puede afectar el cumplimiento de supuestos fundamentales, particularmente la normalidad de los errores y la homocedasticidad. En consecuencia, se hace necesario aplicar una transformación que permita estabilizar la varianza y reducir el impacto desproporcionado de las observaciones extremas sobre las estimaciones.

Con este propósito, se utiliza la transformación logarítmica de la variable dependiente, definida como $\log(\text{trip_count} + 1)$. Esta transformación comprime la escala de los datos, disminuyendo la distancia relativa entre valores bajos y altos y reduciendo significativamente el nivel de asimetría de la distribución. Adicionalmente, el término “+1” garantiza que observaciones con valor cero puedan incluirse sin generar indefiniciones matemáticas derivadas del logaritmo.

La efectividad de esta transformación se observa claramente al comparar los principales estadísticos de distribución entre la variable original y su versión transformada. Mientras la variable original presenta niveles extremadamente altos de asimetría y curtosis, la transformación logarítmica reduce estos indicadores a valores considerablemente más cercanos a la normalidad, mejorando sustancialmente las condiciones para la estimación econométrica.

Estadístico	trip_count original	$\log(\text{trip_count} + 1)$
Media	54.68	1.93
Mediana	3	1.39
Asimetría	10.28	1.59
Curtosis	121.58	5.62

Tabla 5. Comparación de estadísticos: trip_count original vs. $\log(\text{trip_count} + 1)$.

Adicionalmente, se utilizaron gráficos Q-Q para evaluar el grado de ajuste de ambas variables frente a una distribución normal teórica. En el caso de la variable original, los puntos se desvían considerablemente de la línea de referencia, evidenciando un comportamiento fuertemente alejado de la normalidad. Por el contrario, la variable transformada presenta una alineación mucho más cercana a la diagonal, especialmente en la parte central de la distribución, lo que confirma una mejora sustancial en sus propiedades estadísticas, aunque persisten ligeras desviaciones en los extremos debido a la presencia de algunos valores atípicos.




Gráfico 1. Q-Q Plot de trip_count original.




Gráfico 2. Q-Q Plot de $\log(\text{trip_count} + 1)$.

Los resultados anteriores se corroboran mediante el análisis gráfico de ambas distribuciones. En el caso de la variable original, el histograma evidencia una fuerte concentración de observaciones en los valores más bajos y una cola extremadamente prolongada hacia la derecha, confirmando la presencia de una distribución altamente sesgada. Por el contrario, la distribución de $\log(\text{trip_count} + 1)$ presenta una forma más simétrica y compacta, reflejando una reducción importante en la dispersión y en la influencia de los valores atípicos.




Gráfico 3. Distribución de trip_count original.




Gráfico 4. Distribución de $\log(\text{trip_count} + 1)$.

En consecuencia, y con el fin de garantizar una mayor validez estadística en los análisis posteriores, se adopta la variable transformada $\log(\text{trip_count} + 1)$ como variable dependiente en la totalidad de los modelos econométricos desarrollados en este estudio.

3.3 Comportamiento de la demanda por variable

Con el propósito de identificar patrones preliminares en la demanda de viajes, se analizaron gráficamente las relaciones entre la variable dependiente transformada, $\log(\text{trip_count} + 1)$, y las principales variables explicativas consideradas en el modelo. Este análisis exploratorio permite reconocer tendencias generales, diferencias entre grupos y posibles relaciones no lineales antes de realizar la estimación econométrica formal.

En primer lugar, la distribución de la demanda por barrio de origen evidencia una marcada heterogeneidad espacial. Tal como se observa en el Gráfico 5, Manhattan concentra consistentemente los mayores niveles de demanda, presentando valores de $\log(\text{trip_count} + 1)$ significativamente superiores a los registrados en los demás barrios. En contraste, zonas como Staten Island y EWR exhiben niveles considerablemente más bajos y con menor dispersión. Este comportamiento refleja la alta concentración de actividad económica, turística y comercial en Manhattan, consolidándose como el principal núcleo de movilidad de la ciudad.




Gráfico 5. Distribución de $\log(\text{trip_count} + 1)$ por barrio de origen.

Por otro lado, el análisis temporal revela patrones claramente diferenciados a lo largo del día. Como se aprecia en el Gráfico 6, la demanda presenta un mínimo pronunciado durante la madrugada, particularmente alrededor de las 4:00 a.m., y posteriormente inicia una tendencia creciente que alcanza sus niveles más altos entre las 14:00 y las 19:00 horas. Aunque las franjas tradicionalmente consideradas como horas pico muestran una mayor actividad, el comportamiento observado sugiere que la demanda permanece elevada durante gran parte de la jornada diurna y de la tarde, más allá de los desplazamientos laborales convencionales.




Gráfico 6. Promedio de $\log(\text{trip_count} + 1)$ por hora del día.

Adicionalmente, las diferencias según el tipo de pago muestran que los viajes realizados mediante tarjeta presentan una mediana y una variabilidad superiores frente a los pagos en efectivo, tal como se evidencia en el Gráfico 7. Asimismo, aunque todas las categorías presentan valores atípicos, la dispersión observada confirma la existencia de episodios de demanda extraordinariamente alta independientemente del método de pago utilizado.




Gráfico 7. $\log(\text{trip_count} + 1)$ según tipo de pago.

En cuanto al efecto del tipo de día, el Gráfico 8 muestra que los días festivos registran una ligera reducción en la demanda promedio frente a los días ordinarios. Aunque visualmente la diferencia no es extrema, sí anticipa la posibilidad de encontrar efectos estadísticamente significativos en las pruebas de comparación de medias desarrolladas posteriormente.




Gráfico 8. $\log(\text{trip_count} + 1)$ en días festivos vs. Ordinarios.

Finalmente, las variables climáticas presentan una relación visualmente débil con la demanda. Como se observa en el Gráfico 9, la temperatura máxima no evidencia una tendencia clara sobre el comportamiento de $\log(\text{trip_count} + 1)$, mientras que el Gráfico 10 muestra distribuciones muy similares entre días con lluvia y días sin precipitación. Estos resultados sugieren que la demanda de transporte presenta una relativa inelasticidad frente a las condiciones climáticas y que los factores temporales y geográficos tienen un peso considerablemente mayor en la explicación del número de viajes.




Gráfico 9. Relación entre $\log(\text{trip_count} + 1)$ y temperatura máxima.




Gráfico 10. $\log(\text{trip_count} + 1)$ en días con lluvia vs. sin lluvia.

3.4 Resumen por barrio de origen

El análisis descriptivo por barrio de origen evidencia una marcada heterogeneidad espacial en la demanda de viajes dentro de la ciudad de Nueva York. Como se observa en la Tabla 6, Manhattan concentra ampliamente la mayor actividad del sistema, con un promedio de 105.04 viajes por registro y niveles de dispersión considerablemente superiores al resto de barrios. En contraste, zonas como Staten Island y EWR presentan promedios cercanos a un viaje por observación, reflejando una participación mucho más reducida dentro de la dinámica general del transporte.

De manera intermedia, Queens y Brooklyn registran niveles moderados de demanda, mientras que el Bronx presenta valores relativamente bajos en comparación con Manhattan. Estas diferencias reflejan dinámicas urbanas y económicas diferenciadas entre los barrios, asociadas a factores como densidad poblacional, centralidad económica y conectividad. En consecuencia, la variable borough se perfila como uno de los determinantes más relevantes en la explicación del comportamiento de la demanda y tendrá un papel central en la estimación de los modelos econométricos posteriores.

Barrio	N	Promedio	Mediana	Desviación	Máximo	Mínimo
Manhattan	296,867	105.04	5	461.95	7,242	1
Queens	251,737	13.24	3	35.04	577	1
Brooklyn	63,804	4.62	2	7.78	94	1
Bronx	24,391	2.73	1	3.17	29	1
EWR	875	1.07	1	0.28	4	1
Staten Island	251	1.01	1	0.11	2	1

Tabla 6. Resumen de trip_count por barrio de origen.

4. Diferencias en la demanda de viajes

4.1 Metodología (pruebas t y ANOVA)

Para evaluar diferencias entre grupos se utilizan herramientas estadísticas de inferencia. En el caso de comparaciones entre dos grupos, como días festivos frente a días ordinarios o horas pico frente a horas valle, se emplea la prueba t de Welch, la cual no asume igualdad de varianzas entre grupos y resulta apropiada dada la naturaleza de los datos. Por otro lado, cuando se comparan más de dos grupos, como en el caso de los barrios de origen, se utiliza un análisis de varianza (ANOVA), que permite determinar si existen diferencias significativas entre las medias de múltiples categorías.

Dado que la variable trip_count original presenta una distribución altamente asimétrica, todas las pruebas fueron realizadas utilizando como variable de análisis la transformación

$\log(\text{trip_count} + 1)$, lo que permite mejorar la estabilidad de la varianza y obtener resultados estadísticamente más robustos. Adicionalmente, los resultados fueron complementados mediante intervalos de confianza al 95% y representaciones gráficas, con el fin de facilitar la interpretación visual de las diferencias encontradas entre grupos.

4.2 Festivos vs. días ordinarios

El análisis comparativo entre días festivos y días ordinarios evidencia la existencia de diferencias estadísticamente significativas en la demanda de viajes. Como se observa en la Tabla 7, los días ordinarios presentan un promedio de $\log(\text{trip_count} + 1)$ superior al registrado en días festivos, lo que indica una mayor intensidad en el uso del servicio de transporte durante jornadas laborales y de actividad económica regular. Esta diferencia fue evaluada mediante una prueba t de Welch, obteniendo un valor p inferior a 0.05, por lo que se rechaza la hipótesis nula de igualdad de medias.

Los resultados sugieren que la movilidad urbana disminuye durante los días festivos, posiblemente debido a una reducción en desplazamientos asociados al trabajo, actividades comerciales y rutinas cotidianas. Aunque la magnitud de la diferencia no es extremadamente elevada, el tamaño de la muestra permite identificar un efecto estadísticamente robusto y consistente.

Grupo	N	Promedio log	Desviación	IC inferior	IC superior
Día ordinario	620,969	1.9276	1.4747	1.9239	1.9313
Festivo	16,956	1.8711	1.404	1.85	1.8923

Tabla 7. Comparación de medias: días festivos vs. días ordinarios.

Adicionalmente, los intervalos de confianza al 95% no se solapan, lo que refuerza la evidencia de una diferencia real entre ambos grupos. Este resultado sugiere que la actividad económica y laboral durante los días ordinarios genera una mayor demanda de servicios de transporte en comparación con los días festivos, donde los patrones de movilidad tienden a ser distintos, como se muestra en el Gráfico 11.




Gráfico 11. Promedio de $\log(\text{trip_count} + 1)$ con IC 95%: festivos vs. días ordinarios.

4.3 Horas pico vs. horas valle

El análisis por franja horaria muestra diferencias estadísticamente significativas en la demanda de viajes a lo largo del día. Como se presenta en la Tabla 8, la hora pico de la tarde (17:00–19:00) registra el mayor nivel promedio de demanda en escala logarítmica, seguida por la hora pico de la mañana y, finalmente, por las horas valle. Estos resultados fueron evaluados mediante pruebas t de Welch, obteniéndose valores p inferiores a 0.05, lo que permite rechazar la hipótesis nula de igualdad de medias entre las distintas franjas horarias.

La mayor concentración de viajes durante la tarde refleja la dinámica urbana asociada al cierre de la jornada laboral, actividades comerciales y desplazamientos recreativos. En contraste, las horas valle presentan niveles más bajos de actividad, aunque mantienen un volumen importante de viajes debido al carácter continuo del sistema de transporte en Nueva York.

Franja horaria	N	Promedio log	Desviación	IC inferior	IC superior
Hora pico tarde (5-7pm)	94,895	2.0253	1.5691	2.0153	2.0353
Hora pico mañana (7-9am)	74,905	1.8994	1.412	1.8893	1.9095
Hora valle	468,125	1.9103	1.4614	1.9061	1.9144

Tabla 8. Comparación de medias por franja horaria.

Adicionalmente, el análisis gráfico permite observar la evolución continua de la demanda. Como se aprecia en el Gráfico 12, aunque las zonas sombreadas marcan las horas pico tradicionales, la actividad no decae entre ellas. Por el contrario, alcanza su punto máximo absoluto hacia las 14:00 y 15:00 horas, manteniendo una banda de confianza (IC 95%) estrecha que indica una alta estabilidad en el comportamiento de los usuarios. Esto se ratifica en el Gráfico 13, donde las barras de error no se solapan, confirmando visualmente que la hora pico tarde es significativamente superior a las demás franjas, consolidándose como el periodo de mayor presión para el servicio de transporte.




Gráfico 12. Evolución hora a hora de $\log(\text{trip_count} + 1)$ con banda de IC 95%. Zonas sombreadas indican horas pico.




Gráfico 13. Promedio de $\log(\text{trip_count} + 1)$ con IC 95% por franja horaria.

4.4 Comparación entre barrios

El análisis de varianza (ANOVA) confirma la existencia de diferencias estadísticamente significativas en la demanda de viajes entre los distintos barrios de origen de Nueva York. El estadístico obtenido y el valor p asociado permiten rechazar la hipótesis nula de igualdad de medias, evidenciando que el componente geográfico desempeña un papel fundamental en la explicación del comportamiento de la demanda.

Como se observa en la Tabla 9, Manhattan presenta el mayor promedio de $\log(\text{trip_count} + 1)$, muy por encima del resto de barrios, seguido por Queens y Brooklyn. Por el contrario, el Bronx, EWR y Staten Island registran niveles considerablemente menores. Estas diferencias reflejan dinámicas urbanas diferenciadas asociadas a factores como densidad poblacional, actividad económica, centralidad y conectividad dentro de la ciudad.

Barrio	N	Promedio log	Desviación	IC inferior	IC superior
Manhattan	296,867	2.332	1.741	2.326	2.338
Queens	251,737	1.694	1.144	1.69	1.699
Brooklyn	63,804	1.285	0.797	1.278	1.291
Bronx	24,391	1.112	0.568	1.105	1.119
EWR	875	0.719	0.106	0.712	0.726
Staten Island	251	0.698	0.044	0.693	0.704

Tabla 9. Promedio de $\log(\text{trip_count} + 1)$ con IC 95% por barrio de origen.

La robustez estadística de estos hallazgos se ve respaldada por la evidencia visual de los gráficos analizados. En el Gráfico 14, la separación entre los intervalos de confianza al 95% confirma que los contrastes en la demanda entre Manhattan y los demás distritos son estadísticamente significativos. Esta ausencia de solapamiento garantiza que las variaciones observadas no responden al azar muestral, sino a una diferenciación real en el comportamiento de cada barrio.

Por otro lado, la inspección de la distribución completa en el Gráfico 15 revela que Manhattan no solo lidera en promedio, sino que exhibe una mayor variabilidad y una densa presencia de valores atípicos en la parte superior de la escala, lo que sugiere una frecuencia superior de eventos de alta demanda en comparación con las zonas periféricas. De modo que, estos hallazgos confirman una marcada heterogeneidad, donde la centralidad económica y la densidad poblacional de cada barrio dictan la intensidad de uso del servicio de transporte.




Gráfico 14. Promedio de $\log(\text{trip_count} + 1)$ con IC 95% por barrio de origen.




Gráfico 15. Distribución completa de $\log(\text{trip_count} + 1)$ por barrio de origen.

5. Modelo econométrico de la demanda

5.1 Especificación del modelo

Con el propósito de identificar los principales determinantes de la demanda de viajes en la ciudad de Nueva York, se estimó un modelo de regresión lineal múltiple utilizando como variable dependiente la transformación logarítmica $\log[\tilde{f}_0](\text{trip_count}+1)$. La utilización de esta

transformación se justifica a partir del diagnóstico realizado en la sección anterior, donde se evidenció que la variable original presentaba altos niveles de asimetría y curtosis, incompatibles con los supuestos del modelo lineal clásico.

La especificación del modelo incorpora variables temporales, geográficas, operativas y climáticas, seleccionadas con base en la literatura y en los patrones identificados durante el análisis exploratorio. En particular, se incluyen la hora del día, la condición de festivo, el barrio de origen, el tipo de pago, el número de pasajeros, la temperatura máxima y la presencia de lluvia. De esta manera, el modelo busca capturar tanto los factores estructurales asociados a la dinámica urbana como las condiciones operativas y ambientales que podrían influir sobre el comportamiento de la demanda. La especificación general estimada es la siguiente:

$$\log(\text{trip_count} + 1) = \beta_0 + \beta_1 \text{hour} + \beta_2 \text{holiday_usa} + \beta_3 \text{U_Borough} + \beta_4 \text{payment_type} + \beta_5 \text{passanger_count} + \beta_6 \text{tmax_f} + \beta_7 \text{rain} + \varepsilon$$

Donde ε representa el término de error aleatorio. Las variables categóricas fueron incorporadas mediante variables dummy, tomando categorías de referencia para cada grupo. En el caso de los barrios, el Bronx se utilizó como categoría base, mientras que para el tipo de pago se tomó como referencia el pago con tarjeta.

Al trabajar con una variable dependiente en escala logarítmica, los coeficientes pueden interpretarse como variaciones aproximadas porcentuales en la demanda de viajes frente a cambios en las variables explicativas, manteniendo constantes las demás condiciones del modelo. Esta especificación permite evaluar simultáneamente el efecto relativo de múltiples factores sobre el comportamiento de la demanda.

5.2 Construcción progresiva del modelo

Con el fin de evaluar el aporte individual de cada grupo de variables sobre la explicación de la demanda, el modelo econométrico fue construido de manera progresiva mediante cuatro etapas sucesivas. Esta estrategia permite identificar cómo cambia el poder explicativo del modelo a medida que se incorporan nuevas dimensiones de análisis, así como determinar cuáles variables generan las mayores mejoras en el ajuste estadístico.

En una primera etapa se incorporaron únicamente variables temporales, específicamente la hora del día y la condición de festivo. Posteriormente, se añadieron las variables geográficas relacionadas con el barrio de origen, seguido de las variables operativas asociadas al tipo de pago y número de pasajeros. Finalmente, se incluyeron las variables climáticas correspondientes a temperatura máxima y presencia de lluvia. Para cada especificación se evaluaron indicadores de desempeño como el R^2 , el R^2 ajustado, el criterio de información de Akaike (AIC) y el estadístico F.

Como se observa en la Tabla 10, el Modelo 1 presenta un poder explicativo reducido ($R^2=0.0065$), lo que indica que las variables temporales, aunque significativas, explican

únicamente una pequeña proporción de la variabilidad de la demanda. Sin embargo, la incorporación de las variables geográficas en el Modelo 2 genera el incremento más importante en la capacidad explicativa del modelo, elevando el R^2 hasta 0.0852. Este resultado confirma que la ubicación geográfica constituye uno de los determinantes más relevantes del comportamiento de los viajes.

Posteriormente, el Modelo 3 incorpora variables operativas y presenta el mayor salto en ajuste estadístico, alcanzando un R^2 de 0.3335. Esto evidencia que factores como el tipo de pago y el número de pasajeros tienen una relación importante con el volumen de viajes registrado. Finalmente, la inclusión de variables climáticas en el Modelo 4 produce una mejora marginal en el ajuste, aunque suficiente para obtener el menor AIC y el mayor R^2 ajustado del conjunto de especificaciones evaluadas.

Modelo	R^2	R^2 ajustado	AIC	F-estadístico
Modelo 1: temporales	0.0065	0.0065	2,300,231	2,072.45
Modelo 2: + geográficas	0.0852	0.0852	2,247,545	8,490.72
Modelo 3: + operativas	0.3335	0.3335	2,045,525	29,023.22
Modelo 4: + climáticas (final)	0.3336	0.3336	2,045,500	24,561.33

Tabla 10. Resumen comparativo de modelos progresivos.

Al comparar las distintas especificaciones, se evidencia que las variables geográficas y operativas son las que aportan la mayor capacidad explicativa al modelo, mientras que las variables climáticas tienen un efecto relativamente limitado sobre la demanda agregada. Estos resultados son consistentes con los hallazgos del análisis exploratorio, donde se observó que la demanda estaba principalmente determinada por factores espaciales y temporales más que por condiciones meteorológicas.

5.2.1 Modelo 1: Variables temporales

La primera especificación incorpora únicamente variables temporales, específicamente la hora del día y la condición de festivo, con el objetivo de evaluar su capacidad explicativa sobre la demanda de viajes. Los resultados muestran que ambas variables presentan efectos estadísticamente significativos: la variable *hour* tiene una relación positiva con la demanda, mientras que *holiday_usa* presenta un efecto negativo, indicando que los días festivos registran un menor número promedio de viajes en comparación con los días ordinarios.

Sin embargo, pese a la significancia estadística de estas variables, el poder explicativo del modelo es reducido, alcanzando un R^2 de apenas 0.0065. Esto sugiere que los factores temporales, aunque relevantes, no son suficientes para explicar de manera integral el

comportamiento de la demanda, haciendo necesaria la incorporación de variables geográficas y operativas en las siguientes etapas del modelo.

5.2.2 Modelo 2: + Variables geográficas

En la segunda etapa se incorporaron las variables geográficas asociadas al barrio de origen (PU_Borough). La inclusión de estas variables genera un incremento importante en la capacidad explicativa del modelo, elevando el R^2 de 0.0065 a 0.0852, lo que confirma que la localización geográfica es uno de los principales determinantes de la demanda de viajes. Los coeficientes estimados muestran que Manhattan presenta un efecto positivo significativamente superior respecto al Bronx, mientras que Queens y Brooklyn también registran niveles de demanda más altos. Estos resultados son consistentes con los patrones observados en el análisis exploratorio, donde Manhattan concentraba la mayor actividad del sistema de transporte.

5.2.3 Modelo 3: + Variables operativas

En la tercera etapa se incorporaron variables operativas relacionadas con el funcionamiento del servicio, específicamente el tipo de pago y el número de pasajeros. La inclusión de este grupo de variables genera el mayor incremento en la capacidad explicativa del modelo, elevando el R^2 de 0.0852 a 0.3335 y reduciendo considerablemente el valor del AIC. Este resultado evidencia que las características operativas de los viajes tienen una relación importante con el comportamiento de la demanda.

Los coeficientes estimados muestran que el tipo de pago influye significativamente sobre el número de viajes registrados. En particular, las categorías distintas al pago con tarjeta presentan efectos negativos respecto a la categoría de referencia, siendo más pronunciado en algunas modalidades de pago alternativas. Asimismo, la variable `passenger_count` presenta una relación negativa con la demanda agregada, indicando que los grupos con un mayor número de pasajeros tienden a registrar un menor volumen de viajes. En conjunto, estos resultados muestran que las variables operativas aportan información sustancial para explicar la dinámica del sistema de transporte y permiten capturar diferencias relevantes en el comportamiento de los usuarios que no eran explicadas únicamente por factores temporales o geográficos.

5.2.4 Modelo 4: + Variables climáticas

En la cuarta y última etapa se incorporaron las variables climáticas correspondientes a la temperatura máxima diaria y la presencia de lluvia, con el propósito de evaluar si las condiciones meteorológicas afectan el comportamiento de la demanda de viajes. La inclusión de estas variables genera una mejora marginal en el ajuste del modelo, aumentando el R^2 de 0.3335 a 0.3336, obteniendo el menor valor de AIC entre todas las especificaciones estimadas.

Los resultados muestran que la temperatura máxima presenta un efecto positivo y estadísticamente significativo sobre la demanda, aunque de magnitud reducida, lo que sugiere que días con temperaturas más altas tienden a registrar ligeramente más viajes. Por otro lado,

la variable de lluvia no resulta estadísticamente significativa, indicando que, una vez controlados los factores temporales, geográficos y operativos, las precipitaciones no generan cambios importantes en el volumen agregado de viajes.

Estos hallazgos son consistentes con el análisis exploratorio realizado previamente, donde las variables climáticas mostraban relaciones visualmente débiles con la demanda. En consecuencia, aunque las condiciones meteorológicas aportan cierta información adicional al modelo, los principales determinantes del comportamiento de los viajes continúan siendo los factores espaciales y operativos.

5.3 Selección del modelo final

A partir de las cuatro especificaciones estimadas, se selecciona el Modelo 4 como modelo final del estudio, debido a que presenta el mejor desempeño estadístico global. En particular, este modelo registra el mayor R^2 ajustado (0.3336) y el menor valor del criterio de información de Akaike ($AIC = 2,045,500$), lo que indica una mejor capacidad explicativa. Aunque la incorporación de las variables climáticas genera una mejora marginal respecto al Modelo 3, su inclusión permite obtener la especificación más completa y consistente para el análisis de la demanda.

Los resultados confirman que las variables geográficas y operativas son las que tienen el mayor impacto sobre el comportamiento de los viajes. En particular, Manhattan presenta el coeficiente positivo más elevado respecto al barrio de referencia (Bronx), evidenciando que esta zona concentra significativamente más actividad de transporte que el resto de la ciudad. De igual manera, Queens y Brooklyn también muestran efectos positivos importantes, mientras que EWR y Staten Island presentan niveles de demanda considerablemente menores.

Por otro lado, las variables asociadas al tipo de pago muestran efectos estadísticamente significativos y negativos respecto a la categoría base, indicando diferencias importantes en los patrones de uso del servicio según el método de pago utilizado. Asimismo, la variable `passenger_count` presenta una relación negativa con la demanda agregada, sugiriendo que los grupos con mayor número de pasajeros registran menores volúmenes de viajes.

En cuanto a las variables climáticas, la temperatura máxima presenta un efecto positivo aunque reducido, mientras que la variable de lluvia no resulta estadísticamente significativa. Esto refuerza la evidencia observada previamente en el análisis exploratorio, donde las condiciones meteorológicas mostraban una influencia limitada sobre la demanda de viajes.

Variable	Coeficiente	Error std.	IC inf.	IC sup.	Valor p	Sig.
(Intercept)	1.4409	0.0103	1.4208	1.461	< 0.001	***
hour	0.0293	0.0002	0.0289	0.0298	< 0.001	***
holiday_usa1	-0.0684	0.0094	-0.0869	-0.05	< 0.001	***
PU_BoroughBrooklyn	0.4422	0.0091	0.4244	0.46	< 0.001	***
PU_BoroughEWR	-0.3405	0.0414	-0.4216	-0.2594	< 0.001	***
PU_BoroughManhattan	2.1778	0.0083	2.1616	2.194	< 0.001	***
PU_BoroughQueens	1.4013	0.0083	1.3851	1.4175	< 0.001	***
PU_BoroughStatens Island	-0.1262	0.0763	-0.2757	0.0233	0.098	.
payment_type2	-0.6961	0.0034	-0.7028	-0.6894	< 0.001	***
payment_type3	-1.7787	0.0063	-1.791	-1.7664	< 0.001	***
payment_type4	-1.5834	0.005	-1.5932	-1.5737	< 0.001	***
passenger_count	-0.4462	0.0012	-0.4486	-0.4438	< 0.001	***
tmax_f	0.0005	0.0001	0.0003	0.0006	< 0.001	***
rain1	-0.0031	0.0032	-0.0093	0.0032	0.339	

Tabla 11. Coeficientes del modelo final con intervalos de confianza al 95%.

Adicionalmente, el Gráfico 16 permite visualizar de manera más clara la magnitud relativa de los coeficientes estimados en el modelo final. Se observa que las variables asociadas al barrio de origen presentan los efectos más fuertes sobre la demanda, particularmente Manhattan, cuyo coeficiente supera ampliamente al resto de categorías. Asimismo, algunas modalidades de pago muestran efectos negativos considerables, mientras que variables como temperatura y lluvia presentan impactos mucho más reducidos. Esta evidencia confirma que los factores geográficos y operativos son los principales determinantes del comportamiento de la demanda de viajes en Nueva York.




Gráfico 16. Coeficientes del modelo final ordenados por magnitud.

6. Evaluación y validación del modelo

6.1 Bondad de ajuste (R^2 y R^2 ajustado)

El modelo final presenta un R^2 y un R^2 ajustado de 0.3336, lo que indica que aproximadamente el 33.36% de la variabilidad observada en $\log_{10}(\text{trip_count}+1)$ es explicada por las variables incluidas en la especificación. Asimismo, el estadístico F del modelo alcanza un valor de 24,561.33 con un valor p inferior a 0.001, confirmando que el conjunto de variables explicativas resulta estadísticamente significativo de manera conjunta.

Si bien el nivel de ajuste puede considerarse moderado, este resultado es consistente con la naturaleza del fenómeno analizado. La demanda de taxis en una ciudad como Nueva York depende de múltiples factores difíciles de observar o medir, tales como eventos masivos, condiciones del tráfico, obras urbanas, cambios de comportamiento de los usuarios o dinámicas económicas de corto plazo. En este sentido, el modelo logra capturar de manera adecuada los componentes sistemáticos y estructurales de la demanda, particularmente aquellos asociados a factores temporales, geográficos y operativos.

6.2 Análisis de residuos

El análisis gráfico de residuos permite evaluar el comportamiento general del ajuste del modelo y detectar posibles desviaciones respecto a los supuestos clásicos de regresión lineal. En el Gráfico 17 se comparan los valores reales observados frente a los valores ajustados por el modelo. La nube de puntos evidencia una relación positiva entre ambas variables, indicando que el modelo logra capturar de manera razonable la tendencia general de la demanda.

No obstante, también se observa una dispersión considerable alrededor de la línea de ajuste, especialmente en niveles altos de demanda. Este comportamiento es consistente con la naturaleza heterogénea de los datos y con la presencia de eventos extremos asociados a ciertos barrios y franjas horarias. Aun así, no se identifican patrones sistemáticos que sugieran problemas severos de especificación funcional.




Gráfico 17. Valores reales vs. valores ajustados.

6.3 Verificación de supuestos

6.3.1 Normalidad

La normalidad de los residuos fue evaluada mediante la prueba de Shapiro-Wilk aplicada sobre una muestra aleatoria de 5,000 observaciones. Los resultados arrojan un estadístico $W=0.97$ con un valor p inferior a 0.001, lo que indica desviaciones respecto a la normalidad teórica, particularmente en las colas de la distribución.

Sin embargo, este resultado es esperado en bases de datos masivas y con variables de conteo altamente asimétricas como las utilizadas en este estudio. Además, dado el gran tamaño muestral disponible ($N=637,925$), los estimadores mantienen propiedades asintóticas adecuadas, por lo que pequeñas desviaciones de normalidad no comprometen la validez general de las inferencias realizadas.

La evaluación gráfica de los residuos confirma estos resultados. El histograma de residuos evidencia una fuerte concentración alrededor de cero, aunque persisten ligeras colas pesadas asociadas a observaciones extremas. De manera complementaria, el gráfico Q-Q de residuos estandarizados muestra un alineamiento razonable respecto a la línea teórica en la mayor parte de la distribución, con desviaciones principalmente en los extremos.




Gráfico 18. Distribución de los residuos del modelo.




Gráfico 19. Q-Q Plot de residuos estandarizados.

6.3.2 Homocedasticidad

La presencia de homocedasticidad fue evaluada mediante la prueba de Breusch-Pagan. Los resultados muestran un estadístico BP=150,763 con un valor p inferior a 0.001, indicando evidencia de heterocedasticidad en los residuos del modelo. Este resultado también es

consistente con la naturaleza de la base de datos, ya que el comportamiento de la demanda presenta niveles de variabilidad muy distintos entre barrios, horarios y tipos de viaje. En contextos urbanos complejos y con muestras de gran tamaño, este tipo de comportamiento es frecuente y no invalida las conclusiones generales del modelo, especialmente considerando la robustez de los estimadores bajo propiedades asintóticas.

6.3.3 Linealidad

La inspección visual del gráfico de residuos frente a valores ajustados no evidencia patrones curvilíneos pronunciados ni estructuras sistemáticas que sugieran problemas severos en la especificación funcional del modelo. Aunque se observa cierta dispersión creciente asociada a la heterogeneidad de la demanda y al gran tamaño muestral, el comportamiento general de los residuos se mantiene relativamente aleatorio alrededor de cero.

Estos resultados sugieren que la especificación lineal utilizada logra aproximar de manera razonable la relación entre las variables explicativas y la demanda de viajes, respaldando la pertinencia de la forma funcional adoptada en el modelo econométrico.




Gráfico 20. Residuos estandarizados vs. valores ajustados.

6.4 Heterogeneidad por barrio

Con el fin de evaluar posibles diferencias estructurales en el comportamiento de la demanda, se estimaron modelos separados para cada barrio de origen. Los resultados evidencian una heterogeneidad importante tanto en el poder explicativo como en el efecto de algunas variables entre zonas de la ciudad.

Como se observa en la Tabla 12, Queens presenta el mayor nivel de ajuste ($R^2=0.4377$), seguido por Brooklyn (0.3044) y Manhattan (0.2321). En contraste, EWR y Staten Island presentan capacidades explicativas considerablemente menores, lo que puede asociarse al reducido número de observaciones y a una dinámica de demanda más limitada en estas zonas.

Adicionalmente, algunos coeficientes presentan diferencias relevantes entre barrios. Por ejemplo, la variable hour tiene un efecto positivo en Manhattan y Queens, mientras que en el Bronx el coeficiente es negativo, lo que sugiere dinámicas temporales distintas entre áreas centrales y periféricas. Estos resultados confirman que el comportamiento de la demanda no es homogéneo dentro de la ciudad y respaldan la importancia de incorporar variables geográficas en la especificación general del modelo.

Barrio	N	R ²	R ² ajustado	Coef. hour	Coef. tmax	Coef. rain
Queens	251,737	0.4377	0.4377	0.0334	0.0015	-0.0087
Brooklyn	63,804	0.3044	0.3043	-0.0015	0.0011	-0.0083
Manhattan	296,867	0.2321	0.2321	0.035	-0.0005	0.0041
Bronx	24,391	0.18	0.1798	-0.0181	0.0002	0.002
EWR	875	0.0176	0.0086	0.0017	0	0.0047
Staten Island	251	0.0199	-0.0125	-0.0002	0.0001	0.0087

Tabla 12. Heterogeneidad del modelo por barrio de origen.

7. Dashboard interactivo

7.1 Descripción general del dashboard

El desarrollo del dashboard interactivo tuvo como propósito trasladar los principales hallazgos econométricos y descriptivos del estudio a una herramienta visual, dinámica y de fácil interpretación para usuarios del sector transporte en Nueva York. La aplicación fue construida en la librería Shiny de R y permite explorar el comportamiento de la demanda de taxis mediante filtros interactivos que actualizan los resultados en tiempo real según las condiciones seleccionadas por el usuario.

La herramienta integra los resultados obtenidos en el modelo econométrico, las comparaciones de medias y el análisis exploratorio, permitiendo transformar el análisis estadístico en una aplicación orientada a la toma de decisiones operativas. De esta manera, el dashboard facilita la identificación de patrones de demanda asociados al horario, barrio de origen, clima, tipo de pago y características del servicio.

El dashboard fue estructurado en cuatro módulos principales siendo estos un predictor de viajes, un estimador de tarifa, un comparador de barrios y un módulo de análisis por hora. Cada uno de estos componentes permite visualizar diferentes dimensiones de la demanda de

transporte y complementar la interpretación de los resultados obtenidos en las secciones anteriores. La aplicación fue desarrollada en la librería Shiny de R y puede ejecutarse localmente desde RStudio, funcionando como herramienta interactiva de apoyo para la toma de decisiones en el sector transporte.

7.2 Módulo predictor de viajes

El primer módulo del dashboard corresponde al predictor de viajes, diseñado para estimar la demanda esperada de taxis a partir de las variables incluidas en el modelo econométrico final. El usuario puede seleccionar de manera interactiva el barrio de origen, la hora del día, el tipo de pago, la temperatura máxima, la presencia de lluvia, el promedio de pasajeros y si el día corresponde o no a un festivo. Con base en esta información, la aplicación calcula en tiempo real el valor estimado de trip_count utilizando los coeficientes obtenidos en la regresión lineal múltiple.

Además de presentar la estimación puntual del número esperado de viajes, el módulo incorpora una visualización temporal que permite contextualizar el resultado dentro de la dinámica general de demanda durante el día. En esta gráfica, la hora seleccionada por el usuario aparece resaltada, facilitando la identificación de si el escenario corresponde a una franja de alta o baja actividad. Esta funcionalidad permite que empresas del sector transporte evalúen rápidamente cómo cambian los niveles de demanda bajo distintas condiciones operativas y temporales.



Ilustración 1. Módulo predictor de viajes: estimación en tiempo real.

7.3 Módulo estimador de tarifa

El segundo módulo del dashboard corresponde al estimador de tarifa, diseñado para aproximar el valor promedio esperado por viaje bajo distintas condiciones operativas. A partir de variables como el barrio de origen, la hora del día y el tipo de pago, la herramienta calcula una tarifa promedio estimada utilizando la relación entre el monto total recaudado y el número de viajes registrados para cada grupo de observaciones.

Además de presentar la estimación puntual de la tarifa, el módulo incorpora comparaciones visuales entre barrios, permitiendo identificar diferencias espaciales en el comportamiento de los precios promedio del servicio. De esta forma, el usuario puede reconocer qué zonas presentan mayores niveles de recaudo por viaje y cómo estas diferencias se relacionan con patrones de demanda, densidad urbana y dinámica económica.

Este módulo complementa el análisis de demanda desarrollado previamente, ya que no solo permite estimar cuántos viajes podrían ocurrir bajo ciertas condiciones, sino también aproximar el comportamiento económico asociado a dichos desplazamientos. En consecuencia, la herramienta resulta útil para procesos de planificación operativa, asignación de flota y evaluación de rentabilidad dentro del sistema de transporte.




Ilustración 2. Módulo estimador de tarifa por barrio.

7.4 Módulo comparador de barrios

El tercer módulo del dashboard fue diseñado para facilitar el análisis comparativo entre distintos barrios de origen de Nueva York. A través de una interfaz interactiva, el usuario puede seleccionar dos barrios y visualizar de manera simultánea indicadores relevantes asociados a

la demanda de viajes, como el promedio de trip_count, la mediana y la tarifa promedio estimada.

Adicionalmente, el módulo incorpora representaciones gráficas comparativas que permiten analizar la distribución completa de la demanda entre los barrios seleccionados. Estas visualizaciones facilitan la identificación de diferencias en dispersión, concentración y presencia de valores extremos, complementando los hallazgos obtenidos previamente en el análisis exploratorio y en las pruebas de diferencias de medias.

La utilidad principal de este componente radica en permitir una interpretación más intuitiva de la heterogeneidad espacial observada en el sistema de transporte. En particular, evidencia cómo zonas centrales como Manhattan presentan patrones de demanda considerablemente distintos frente a barrios periféricos como Staten Island o EWR, reforzando la importancia del componente geográfico dentro de la modelación econométrica.



Ilustración 3. Módulo comparador de barrios.

7.5 Módulo análisis por hora

El cuarto módulo del dashboard permite analizar la evolución de la demanda de viajes a lo largo del día mediante visualizaciones dinámicas filtrables por barrio de origen. La herramienta muestra el comportamiento promedio de $\log(\text{trip_count} + 1)$ para cada hora, acompañado de bandas de intervalos de confianza al 95%, lo que facilita evaluar tanto la tendencia general como la estabilidad de las estimaciones.

Asimismo, el módulo destaca visualmente las franjas correspondientes a horas pico, permitiendo identificar los momentos de mayor presión sobre el sistema de transporte. Los resultados reflejan una dinámica consistente con los hallazgos econométricos y descriptivos

obtenidos previamente, donde la demanda alcanza sus niveles más altos entre las horas de la tarde y el inicio de la noche.

La incorporación de filtros interactivos posibilita comparar cómo cambia el patrón horario entre barrios, evidenciando nuevamente la existencia de heterogeneidad espacial en la demanda. De esta manera, el módulo constituye una herramienta útil para apoyar decisiones relacionadas con distribución de flota, planeación operativa y asignación de recursos en diferentes momentos del día.



Ilustración 4. Módulo análisis por hora con horas pico destacadas.

7.6 Implementación en Shiny

El dashboard fue desarrollado utilizando la librería Shiny de R, la cual permite construir aplicaciones web interactivas integradas con herramientas de análisis estadístico y visualización de datos. La aplicación fue estructurada mediante módulos independientes que permiten explorar la demanda de viajes, comparar barrios y estimar indicadores operativos en tiempo real. El script completo del dashboard se encuentra disponible en el repositorio del proyecto para su ejecución local desde RStudio.

8. Discusión de resultados

8.1 Principales hallazgos

Los resultados obtenidos permiten identificar patrones claros y consistentes en el comportamiento de la demanda de taxis en Nueva York. En primer lugar, se evidencia que la demanda presenta una fuerte concentración espacial, donde Manhattan se consolida como el principal núcleo de actividad del sistema de transporte. Tanto en el análisis descriptivo como en el modelo econométrico, este distrito registra niveles significativamente superiores al resto

de barrios, reflejando la influencia de factores estructurales como la densidad poblacional, la actividad económica y la centralidad urbana.

En segundo lugar, las variables temporales muestran una alta capacidad explicativa sobre la demanda. Se encontró que las horas de la tarde concentran los mayores niveles de actividad, superando incluso las franjas tradicionalmente asociadas a desplazamientos laborales matutinos. Asimismo, los días ordinarios presentan una demanda significativamente superior a los días festivos, lo que confirma la estrecha relación entre movilidad urbana y actividad económica. Adicionalmente, el modelo econométrico evidencia que las variables operativas, particularmente el tipo de pago y el número promedio de pasajeros, tienen un efecto importante sobre el comportamiento de la demanda. En contraste, las variables climáticas presentan una influencia relativamente limitada, sugiriendo que la demanda de taxis en Nueva York es poco sensible a cambios moderados en temperatura o precipitación.

Finalmente, los análisis de heterogeneidad muestran que el comportamiento de la demanda no es homogéneo entre barrios. Los coeficientes estimados y los niveles de ajuste difieren considerablemente según la zona analizada, indicando que las dinámicas de movilidad urbana responden a características particulares de cada territorio.

8.2 Implicaciones económicas

Los hallazgos del estudio tienen implicaciones relevantes para la planificación y gestión del sistema de transporte urbano. La fuerte concentración de la demanda en Manhattan sugiere que la asignación de flota y recursos operativos debería priorizar las zonas con mayor densidad económica y comercial, especialmente durante las franjas horarias de mayor actividad.

Asimismo, la existencia de diferencias significativas entre horas pico y horas valle permite identificar oportunidades para optimizar la distribución temporal del servicio. En particular, el incremento de la demanda durante la tarde indica la necesidad de fortalecer la disponibilidad de vehículos en este periodo, reduciendo tiempos de espera y mejorando la eficiencia operativa. Por otro lado, la limitada incidencia de las variables climáticas sugiere que la demanda de taxis mantiene una relativa estabilidad incluso frente a cambios en las condiciones meteorológicas. Esto implica que los factores estructurales y temporales tienen un peso considerablemente mayor en la explicación del comportamiento de los usuarios.

Finalmente, el desarrollo del dashboard interactivo representa una herramienta de valor para empresas y tomadores de decisiones, ya que permite transformar resultados econométricos complejos en información práctica y accesible para la planificación operativa y el monitoreo de la demanda en tiempo real.

8.3 Limitaciones del estudio

A pesar de la solidez de los resultados obtenidos, el estudio presenta algunas limitaciones que deben ser consideradas al interpretar los hallazgos. En primer lugar, la base de datos utilizada

no incorpora variables relacionadas con eventos extraordinarios, cierres viales, condiciones de tráfico o actividades masivas, factores que podrían influir significativamente en la demanda de transporte en determinados momentos.

De igual forma, aunque el modelo econométrico logra capturar una proporción importante de la variabilidad de la demanda, existe un componente no observable asociado a comportamientos individuales y dinámicas urbanas que no puede ser explicado únicamente mediante las variables incluidas en el análisis. Esto resulta consistente con la naturaleza compleja y altamente dinámica de los sistemas de movilidad urbana.

Adicionalmente, algunas categorías geográficas, como Staten Island y EWR, presentan un número reducido de observaciones en comparación con otros barrios, lo que limita la precisión estadística de ciertas estimaciones específicas para estas zonas. Finalmente, el análisis se concentra exclusivamente en información agregada proveniente de taxis amarillos de Nueva York, por lo que los resultados no necesariamente son extrapolables a otros sistemas de transporte o plataformas de movilidad privada.

9. Conclusiones y Recomendaciones

El presente estudio permitió analizar de manera integral el comportamiento de la demanda de taxis en Nueva York mediante herramientas de estadística descriptiva, pruebas de diferencias de medias, modelos econométricos y visualización interactiva de datos. Los resultados evidencian que la demanda está principalmente determinada por factores temporales y geográficos, destacándose la relevancia de la hora del día y del barrio de origen como variables fundamentales en la explicación del número de viajes.

La transformación logarítmica de la variable dependiente permitió corregir problemas de asimetría y mejorar el cumplimiento de los supuestos estadísticos del modelo, facilitando una estimación más robusta y estable. Asimismo, el modelo econométrico mostró que Manhattan concentra niveles significativamente superiores de demanda respecto a los demás barrios, mientras que las variables climáticas presentan efectos relativamente reducidos sobre el comportamiento de los usuarios.

Las pruebas de diferencias de medias confirmaron que existen variaciones estadísticamente significativas entre días festivos y ordinarios, así como entre distintas franjas horarias y barrios de origen. Estos resultados reflejan la existencia de patrones sistemáticos en la movilidad urbana y evidencian la importancia de incorporar componentes espaciales y temporales en la planificación del servicio de transporte.

Por otra parte, el desarrollo del dashboard interactivo permitió convertir los resultados estadísticos en una herramienta práctica orientada a usuarios del sector transporte. La aplicación facilita la exploración dinámica de la demanda y constituye un apoyo potencial para procesos de planeación operativa, asignación de flota y monitoreo de indicadores clave.

Como recomendación, futuras investigaciones podrían incorporar variables adicionales relacionadas con tráfico vehicular, eventos masivos, precios dinámicos o información en tiempo real, con el fin de mejorar la capacidad predictiva de los modelos. Asimismo, sería relevante extender el análisis hacia otros medios de transporte urbano o integrar técnicas de aprendizaje automático que permitan capturar relaciones no lineales y patrones más complejos en la demanda.